

비선형 관계와 회귀모델 선택

직선
곡선
조건 분할

잔차에서 한계를 발견하고 다항회귀와 의사결정나무를 비교한다

성능이 낮으면 모델부터 바꾸는 것이 아닙니다

먼저 확인할 질문

**모델은 어디에서,
어떤 모양으로 틀리는가?**


평균 오차만 보면 놓치는 것

- 특정 구간의 반복적인 과소예측
- 곡선 형태의 잔차
- 조건이 바뀌는 경계
- 학습 데이터에만 맞는 복잡한 규칙

다음 모델은 잔차에 남은 구조를 설명할 근거가 있을 때 선택합니다.

선형회귀는 평균 관계를 직선으로 표현합니다

설명용 예시



직선이 적절할 때


X가 변할 때 평균 y가 대체로 일정한 기울기로 변합니다.

직선이 부족할 때

구간에 따라 증가폭이나 방향이 달라집니다.

평균 성능보다 잔차의 반복 패턴을 먼저 봅니다

직선 모델의 잔차 패턴



이 곡선은 우연한 흠어짐이 아닙니다.

가운데에서는 낮게 예측하고 양 끝에서는 높게 예측하는 패턴이 반복됩니다.

잔차 모양에 따라 다음 확인 방법이 달라집니다

01

곡선

제곱항·변환·스플라인처럼 부드러운 비선형 관계를 검토합니다.

02

구간 경계

의사결정나무처럼 조건에 따라 나누는 모델을 검토합니다.

03

깎때기·시간 반복

분산 변화, 누락 변수, 시간 의존성을 먼저 확인합니다.

모든 잔차 문제를 다항회귀나 트리로 해결할 수 있는 것은 아닙니다.

다항회귀는 입력변수의 거듭제곱 항을 추가합니다

선형회귀

$$\hat{y} = \beta_0 + \beta_1 x$$

2차 다항회귀


$$\hat{y} = \beta_0 + \beta_1 x + \beta_2 x^2$$

x가 3이면 모델에는 $x=3$ 과 $x^2=9$ 가 함께 입력됩니다.

새로운 목표값을 만드는 것이 아니라 같은 입력에서 곡선 형태를 표현할 변수를 추가합니다.

x^2 항이 기울기를 위치에 따라 달라지게 합니다

직선과 곡선의 차이



2차식에서는 한 칸 이동할 때의 변화량이 일정하지 않습니다.

β_2 의 부호와 크기가 곡선이 휘는 방향과 정도에 영향을 줍니다.

다중회귀와 다항회귀는 서로 다른 확장입니다

구분	추가하는 것	예시	목적
다중회귀	서로 다른 변수	가격 = 연식 + 주행거리	여러 정보 반영
다항회귀	변수의 거듭제곱	가격 = 연식 + 연식 ²	곡선 관계 표현
함께 사용	변수와 거듭제곱	연식 + 연식 ² + 주행거리	여러 정보와 곡선 반영

“다중”은 변수의 종류, “다항”은 관계의 형태에 관한 구분입니다.

다항회귀는 개별 계수보다 전체 곡선을 해석합니다

주의할 해석

β_1 만 보고 “X가 1 증가하면 y가 β_1 만큼 증가한다”고 말하기 어렵습니다.


권장 해석

대표 X 값에서 예측값과 변화 방향을 계산하고 전체 곡선으로 보여줍니다.

x 와 x^2 가 함께 움직이므로 한 항만 떼어 변화량을 설명하지 않습니다.

차수가 높아질수록 표현력과 과적합 위험이 함께 커집니다


모델 복잡도와 오차(설명용 예시)



학습 오차는 계속 줄어도
검증 오차는 다시 커질 수
있습니다.

차수는 학습 성능이 아니라 새
로운 데이터의 성능으로 선택합
니다.

다항회귀의 외삽은 특히 불안정할 수 있습니다



계산할 수 있다는 것과
믿을 수 있다는 것은 다
릅니다.

학습 범위 밖에서는 작은 곡률
차이가 큰 예측 차이로 확대될
수 있습니다.

다항회귀는 부드러운 곡선에 근거가 있을 때 사용합니다

01

적합한 상황

산점도와 잔차에서 부드러운 곡선이 반복되고 업무적으로도 설명 가능합니다.

02

검증 조건

낮은 차수부터 비교하고 교차검증과 테스트 성능을 확인합니다.

03

피해야 할 상황

경계가 갑자기 바뀌거나 학습 범위 밖 예측이 핵심인 경우입니다.

의사결정나무는 회귀식 대신 조건별 구간을 만듭니다

선형회귀

전체 데이터를 하나의 식으로 연결


의사결정나무

입력값을 조건으로 나누고
각 구간에 예측값을 배정

예: 사용 기간이 짧은 고객과 긴 고객의 구매금액 수준이 뚜렷하게 다르다면
하나의 직선보다 조건으로 구간을 나누는 편이 관계를 더 직접적으로 표현할 수 있습니다.

핵심은 “질문을 따라가는 그림”이 아니라 오차가 작은 구간을 찾는 과정입니다.

나무의 구성: 질문, 가지, 리프



분할 조건: 데이터를 나누는 질문 가지: 조건의 결과 리프: 더 나누지 않는 마지막 구간

후보 분할점은 정렬된 입력값 사이에서 만듭니다

사용 기간 x	1	2	3	6	7	8
실제 구매금액 y	20	24	28	60	65	70
후보 경계		1.5	2.5	4.5	6.5	7.5

4.5는 관측된 값이 아니라 3과 6 사이를 나누기 위한 경계입니다.

변수가 여러 개라면 모든 변수의 후보 경계를 같은 방식으로 비교합니다.

분할 전에는 전체 목표값의 평균으로 예측합니다

20 24 28 60 65 70

전체 평균 = 44.5

제곱오차 합 = $\sum(\text{실제값} - 44.5)^2 = 2,603.5$

낮은 값에는 너무 높고 높은 값에는 너무 낮은 하나의 예측값을 사용하므로 오차가 큼니다.

나무는 이 오차를 줄일 수 있는 조건을 찾기 시작합니다.

각 후보로 나눈 뒤 두 구간의 오차를 더합니다

후보 조건: 사용 기간 ≤ 4.5

왼쪽 구간

$y = 20, 24, 28$

평균 = 24

제곱오차 합 = 32

오른쪽 구간

$y = 60, 65, 70$

평균 = 65

제곱오차 합 = 50

분할 후 오차 = $32 + 50 = 82$

분할 전 2,603.5보다 크게 줄었으므로 이 조건은 유용한 후보입니다.

가장 작은 오차의 분할을 선택합니다

후보 조건	분할 후 제곱오차 합	선택 결과
$X \leq 1.5$	1,883.2	
$X \leq 2.5$	1,084.8	
$X \leq 4.5$	82.0	선택
$X \leq 6.5$	1,016.5	
$X \leq 7.5$	1,823.2	

가장 가운데에 있는 경계를 고르는 것이 아니라 목표값 y 의 오차가 가장 작아지는 경계를 고릅니다.

선택된 두 구간에서 같은 탐색을 반복합니다

01

1. 첫 분할

전체 데이터에서 오차를 가장 많이 줄이는 조건을 선택합니다.

02

2. 반복 분할

왼쪽과 오른쪽 구간에서 다시 후보 조건과 오차를 비교합니다.

03

3. 학습 종료

깊이 제한이나 최소 표본 수에 도달하면 해당 구간을 리프로 남깁니다.

이 반복 과정을 재귀적 분할이라고 하며, 반복할수록 나무가 깊어집니다.

새 관측치는 조건을 따라 리프까지 이동합니다

새 고객: 사용 기간 2개월

- ① 사용 기간 ≤ 4.5 ? → 예
- ② 왼쪽 리프로 이동
- ③ 리프의 학습값 평균 24를 출력

학습: 조건과 경계를 선택하는 과정
예측: 정해진 조건을 따라가는 과정

예측할 때 조건을 새로 찾는 것이 아니라 학습 단계에서 정해진 규칙을 적용합니다.

의사결정나무는 조건으로 데이터를 반복해서 나눕니다



회귀나무의 마지막 구간은 범주가 아니라 연속적인 예측값을 출력합니다.

회귀나무의 마지막 구간은 학습값의 평균을 예측합니다

구간	학습 데이터의 y	구간 평균	새 관측치 예측
$X \leq 4$	22, 28, 35, 43	32	32
$4 < X \leq 7$	60, 67, 72	66.3	66.3
$X > 7$	79, 74, 65	72.7	72.7

같은 마지막 구간에 들어간 관측치는 같은 값을 예측받습니다.

나무는 예측 오차가 가장 많이 줄어드는 분할을 찾습니다

01

분할 전

모든 관측치에 하나의 평균을 예측하고 제곱오차를 계산합니다.

02

후보 비교

$X \leq 3$, $X \leq 4$, $X \leq 5$ 처럼 가능한 기준을 비교합니다.

03


분할 선택

두 구간의 제곱오차 합이 가장 작아지는 기준을 선택합니다.

선택된 기준은 원인이나 자연법칙이 아니라 학습 데이터의 오차를 줄인 조건입니다.

의사결정나무의 예측은 계단 형태입니다

조건별 동일한 예측값



경계 전후에서 예측값이 갑자기 달라집니다.

부드러운 관계를 표현하기보다 구간과 조건이 중요한 관계에 적합합니다.

나무는 변수 간 조건 결합을 자동으로 표현합니다

예측 규칙의 예

온도 > 20°C?

└ 예: 휴일인가?

└└ 예 → 예측 55

└└ 아니요 → 예측 82

└ 아니요: 비가 오는가?

└└ 예 → 예측 18

└└ 아니요 → 예측 41


선형회귀에서는

온도×휴일, 온도×강수처럼 필요한 상호작용 항을 직접 설계해야 합니다.

자동으로 찾았다는 사실이 안정적이거나 인과적인 규칙이라는 뜻은 아닙니다

나무가 깊어질수록 더 작은 집단까지 나눕니다

나무 깊이와 오차(설명용 예시)



깊이를 제한하지 않으면 학습 데이터를 거의 외울 수 있습니다.

깊이는 검증 성능과 마지막 구간
간의 표본 수를 함께 보고 결정
합니다.

리프의 최소 표본 수는 지나치게 작은 규칙을 막습니다

리프 표본 2건

두 사례만 우연히 높은 값을 가져도 별도의 구간이 만들어질 수 있습니다.

리프 표본 30건

각 예측값이 더 많은 사례의 평균이므로 규칙이 안정적인 가능성이 커집니다.

`min_samples_leaf`는 세부 패턴을 포기하는 대신 예측의 변동을 줄이는 설정입니다.

의사결정나무도 학습 범위 밖 추세를 연장하지 못합니다

01

범위 밖 입력

새 값이 기존 규칙을 따라 마지막 구간에 도착합니다.

02

예측 결과

학습 데이터 마지막 구간의 평균 값을 그대로 출력합니다.

03


주의점

증가·감소 추세가 계속된다는 예측이 필요하면 적합하지 않을 수 있습니다.

선형회귀와 다항회귀는 관계를 연장하고, 나무는 기존 구간의 값을 반복합니다.

세 모델은 같은 관계를 서로 다른 모양으로 표현합니다

설명용 예측 형태 비교



직선

전체 방향을 단순하게 요약

곡선

부드러운 변화 표현

조건 구간

경계와 상호작용 표현

모델의 장단점은 성능 하나로 정리되지 않습니다

비교 기준	선형회귀	다항회귀	의사결정나무
관계 형태	직선	부드러운 곡선	조건별 계단
상호작용	직접 추가	직접 추가	분할로 표현
복잡도 조절	변수 수	차수	깊이·리프 크기
외삽	가능하지만 주의	매우 불안정 가능	추세 연장 불가
설명 방식	계수	곡선·대표 예측	분할 규칙

업무 목적에 필요한 관계 형태와 오류 위험을 함께 비교합니다.

교차검증은 하나의 분할에 의존하지 않고 설정을 비교합니다

학습 데이터

분할 1

학습·검증
역할 반복

분할 2

학습·검증
역할 반복

분할 3

학습·검증
역할 반복

분할 4

검증 구간을
순서대로 변경

각 설정의 검증 오차를 평균하여 차수나 깊이를 선택합니다.

교차검증은 테스트 데이터를 여러 번 확인하는 문제를 줄여줍니다.

테스트 데이터는 모델 선택이 끝난 뒤 한 번 사용합니다

01

후보 설정

다항식 차수와 나무 깊이 후보를 정합니다.

02

교차검증

학습 데이터 안에서 평균 검증 성능을 비교합니다.

03

최종 평가

선택된 설정만 테스트 데이터에서 평가합니다.

테스트 결과를 보고 설정을 다시 바꾸면 테스트 데이터도 선택 과정에 사용한 것입니다.

모델 선택은 점수·오류 모양·사용 조건을 함께 판단합니다

판단 질문	확인할 결과
새로운 데이터에서 오차가 작은가	교차검증과 테스트 MAE·RMSE
특정 구간에서 반복해서 틀리는가	잔차 그래프와 구간별 평균 잔차
학습 데이터에만 맞는가	학습·검증 성능 차이
예측 형태가 현실적인가	곡선·경계·외삽 결과
결과를 설명할 수 있는가	계수·곡선·분할 규칙

최고 점수 모델과 가장 적합한 운영 모델은 다를 수 있습니다.

잔차 패턴이 다음 분석 방향을 결정합니다

관찰된 패턴	우선 확인할 것	검토할 모델
무작위로 흩어짐	기준 대비 성능과 오차 크기	선형회귀 유지 가능
부드러운 곡선	변환·누락 변수·차수	낮은 차수의 다항회귀
구간 경계와 조건 결합	표본 수와 경계 안정성	의사결정나무
깎때기·시간 반복	분산 변화·시간 의존성	변환·가중회귀·시계열

모델을 고르기 전에 잔차가 보여주는 문제의 종류를 먼저 구분합니다.

모델 비교는 같은 조건에서 수행합니다

모든 후보에 동일하게 적용

01

같은 데이터

동일한 관측치와 동일한 목표 변수를 사용합니다.

02

같은 분할

같은 교차검증 폴드와 테스트 데이터를 사용합니다.

03

같은 지표

같은 MAE·RMSE와 오류 분석 기준을 사용합니다.

조건이 다르면 모델 차이가 아니라 평가 방법의 차이를 비교하게 됩니다.

복잡한 모델은 단순한 모델보다 충분히 나아야 합니다

기준 순서

평균 기준 모델


- 선형회귀
- 다항회귀
- 의사결정나무

복잡도를 늘릴 근거

- 검증 오차가 의미 있게 감소
- 잔차의 반복 패턴이 줄어들음
- 큰 오류 사례가 개선됨
- 예측 형태가 현실적임
- 운영상 설명과 유지가 가능함

차이가 작다면 더 단순하고 안정적인 모델을 선택할 수 있습니다.

회귀모델 선택의 전체 순서



질문 → 기준 모델 → 오류 구조 → 후보 모델 → 검증 → 선택

모델 선택은 알고리즘 이름이 아니라 오류와 사용 조건에 대한 판단입니다.

모델은 오류 진단과 검증으로 선택합니다

01

오류 진단

선형회귀의 잔차에서
반복되는 오류 모양을 확인합니
다.

점수보다 어디에서 어떻게
틀리는지를 먼저 봅니다.

02

관계 표현

부드러운 곡선
→ 낮은 차수의 다항회귀

조건과 경계
→ 의사결정나무

03

검증과 선택

차수와 깊이는 교차검증으로
선택합니다.

테스트 데이터는 모델 선택 후
한 번만 평가합니다.

점수 · 오류 패턴 · 외삽 · 설명 가능성을 함께 확인합니다.